

分类学 AI Agent 建设指南

v2.1 可实施核实版 - Gemini / MCP / ICZN 修订与落地路线

本版定位

本文件不是重新堆功能，而是把 v2.0 中过于宏大、可能误导实施的部分收敛为一套可落地的研究 workflow。Gemini/GPT/Claude 适合作为调度、审查和写作助手；分类事实、标本数据、序列、坐标和命名学判断必须保留在本地结构化数据和人工审核中。

项目	v2.0 状态	v2.1 修订原则
总体架构	方向正确：专家规则 + 数据库 + 工具 + Agent	保留，但将“MCP + Snakemake + GUI”下放到第二阶段；第一阶段先做 CSV/SQLite + Python CLI。
Gemini/LLM	容易被理解为“万能自动完成分类学流程”	明确为“调度层/审查层/语言层”。Function calling 只给函数名和参数，真正执行仍由本地代码完成。
ICZN 合规	规则写得过于刚性，例如“必须且仅能 1 个 holotype”	改为“硬性规则 + 期刊推荐 + 人工复核”三层。不同发表场景不能用单一 fatal 规则。
影像自动化	景深堆叠、SEM 标尺识别、图版自动化较理想化	改成 metadata-first：先人工确认比例尺和器官标签，OCR/自动识别只作为 review flag。
90 天路线	接近“90 天 v1.0 全自动工作台”	改成“90 天可复现 pilot workflow”。全实验室推广通常需要 3-6 个月。

目录

- 1. 核实结论：哪些保留、哪些必须修正
- 2. Gemini / LLM 在系统中的正确位置
- 3. v2.1 最小可行架构：先本地、后 Agent
- 4. 数据表与字段模板：先让数据可追踪
- 5. ICZN 合规引擎：边界、风险与可执行规则
- 6. 影像与图版：从人工确认元数据开始
- 7. 分子证据：证据链，不是自动判种器
- 8. 比较引擎与检索表：可运行的逻辑修订
- 9. 90 天实施路线：保守、可验收、可扩展
- 10. 附录：v2.1 检查清单与参考来源

1. 核实结论：哪些保留、哪些必须修正

v2.0 的核心方向值得保留：分类学专家经验需要软件化，Agent 不应凭空给出分类事实，unknown 不能被当作 absent，分类学家必须保留最高否决权。v2.1 的重点是把这些原则转成“能跑、能审、能复现”的工程步骤。

模块	保留	修正
证据链	形态、分子、地理、模式标本、影像都要有 evidence record。	不要把任何单一证据直接变成“自动判种”；输出应为候选结论 + 证据等级。
数据库	SQLite/DuckDB 方向合理。	第一阶段不要立即设计复杂关系库；先用 CSV 模板稳定字段，再迁移到 SQLite。
MCP	长期非常适合把本地工具暴露给 AI。	第一阶段不强制 MCP；先让脚本能命令行运行，避免被协议复杂度卡住。
Treatment 组装	模块化写作正确。	禁止“一键终稿”。Diagnosis、Description、Material examined、Remarks

模块	保留	修正
		必须分模块审查。
Benchmark	非常重要。	题库要测试“不会犯错”，而不只是测试“能生成漂亮文本”。

v2.1 总原则

先建立可验证的数据层，再建立可运行的工具层，最后才接入 Gemini/GPT/Claude 做调度与写作。不要反过来先写一个很聪明的聊天界面。

2. Gemini / LLM 在系统中的正确位置

Gemini、GPT、Claude 等模型可以成为 Taxonomy Agent 的“大脑界面”，但不是分类事实数据库。它们适合做任务拆解、JSON 输出、函数调用建议、文献段落摘要、失败案例解释、草稿润色；不适合直接存储性状状态、GenBank 号、馆藏号或命名学结论。

可用	不建议直接依赖
根据自然语言请求决定调用 <code>compare_species_matrix</code> 、 <code>map_qc</code> 、 <code>iczn_check</code> 等工具。	让 LLM 自己判断某个性状“存在/缺失”，除非该状态来自数据库或原文证据。
把本地工具结果转写成 <code>diagnosis/remarks</code> 初稿。	让 LLM 自己生成文献引用、ZooBank LSID、馆藏编号。
读取图像/表格并提出 <code>review flag</code> ，例如“比例尺疑似缺失”。	让 LLM 自动 OCR 比例尺后直接进入图版终稿。
用结构化输出生成 JSON task list。	让 LLM 自动修改核心规则而不经人工批准。

Gemini function calling 的落地理解

模型返回的是“应该调用哪个函数 + 参数是什么”。真正执行函数、读写本地文件、运行 R/Python、生信命令，仍然是你自己的应用负责。因此工具必须先在本地图行可独立运行。

3. v2.1 最小可行架构：先本地、后 Agent

v2.1 把系统拆成四层，但实施顺序从最底层开始：数据模板 → 本地脚本 → CLI → MCP/Agent。

阶段	目标	交付物	验收标准
Phase A: 无 Agent	先把数据和脚本跑通。	CSV 模板、 <code>compare.py</code> 、 <code>map_qc.py</code> 、 <code>treatment_template.md</code> 。	不使用 AI 也能输出差异表和坐标 QC 报告。
Phase B: 轻量 Agent	让 AI 调用已存在的脚本。	function calling / MCP server / CLI wrapper。	同一个输入多次运行结果一致，可回溯日志。
Phase C: 文献与影像	加入文献索引、影像元数据、图注辅助。	<code>literature_index.csv</code> 、 <code>images.csv</code> 、 <code>figure_caption.py</code> 。	每条图注能回到 <code>specimen_id</code> 和原图文件。
Phase D: 工作台	GUI、多属项目、协作、自动化流程。	FastAPI/desktop GUI/Snakemake。	团队成员可复现同一项目流程。

4. 数据表与字段模板：先让数据可追踪

第一版不要直接设计很复杂的数据库。建议先用 CSV/Excel 作为输入层，字段稳定后再导入 SQLite。下面字段是 v2.1 的最小可行集。

文件	关键字段	用途
<code>specimens.csv</code>	<code>specimen_id</code> , <code>catalog_number</code> , <code>institution_code</code> , <code>current_identification</code> , <code>type_status</code> , <code>tissue_id</code> , <code>notes</code>	标本凭证与鉴定状态。
<code>collecting_events.csv</code>	<code>event_id</code> , <code>locality</code> , <code>decimalLatitude</code> , <code>decimalLongitude</code> , <code>geodeticDatum</code> , <code>coordinateUncertaintyInMeters</code> , <code>depth_m</code> ,	采集地点、坐标、生态信息。

文件	关键字段	用途
	habitat, eventDate, recordedBy	
character_ontology.csv	character_id, anatomical_region, data_type, allowed_states, unit, definition, measurement_protocol	性状定义，避免同一性状多种写法。
observations.csv	specimen_id, character_id, value_raw, value_standard, evidence_type, observer, source_reference, page_or_figure, confidence	所有性状状态和证据来源。
images.csv	image_id, specimen_id, anatomical_region, modality, file_path, scale_bar_um, scale_confirmed_by, figure_panel, review_status	影像资产、图版与标本对应关系。
sequences.csv	specimen_id, marker, fasta_path, genbank_accession, alignment_id, sequencing_lab, notes	分子证据与标本对应关系。

必须保留的状态值

UNKNOWN = 未知；NOT_EXAMINED = 未检视；NOT_APPLICABLE = 不适用；ABSENT = 已检视且确认缺如。任何程序都不能把 UNKNOWN 自动改成 ABSENT。

5. ICZN 合规引擎：边界、风险与可执行规则

ICZN checker 不应假装替代命名学专家。它应该像“投稿前强制检查清单”：发现缺项、格式风险、证据不足和需要人工确认的命名学问题。

检查项	v2.1 实施方式	自动化等级
新名称是否有可区分性描述/定义	检查 diagnosis/description 是否存在，并且至少引用一个可追踪的 character/evidence record。不要用“字数 < 50”这种任意规则。	可自动检查缺失；内容质量人工确认。
Holotype / syntypes / depository	若项目选择 holotype 模式，则检查正模唯一、馆藏号和保藏机构存在；若采用 syntypes，则检查是否明确固定。	可自动检查字段；命名选择人工确认。
电子出版与 ZooBank	检查 work-level registration / LSID / 出版日期 / archive / ISSN/ISBN 是否有字段。不要只检查 act LSID 正则。	可自动检查字段；期刊要求人工确认。
种加词性别一致	只做 warn，不做 fatal。noun in apposition、patronym、地名派生词等必须人工判断。	仅提示。
分子证据	遗传距离、系统树、序列差异只能作为证据；不能用单一距离阈值自动判定新种。	仅证据汇总。

iczn_check_minimal.py - v2.1 recommended logic

```
def audit_treatment(treatment):
    issues = []
    # 1. Type-bearing material
    type_mode = treatment.get("type_mode") # holotype / syntypes / other
    if type_mode == "holotype":
        holotype = treatment.get("holotype")
        if not holotype:
            issues.append("FATAL: holotype mode selected, but holotype is missing.")
        elif not holotype.get("catalog_number") or not holotype.get("depository"):
            issues.append("FATAL: holotype lacks catalog_number or depository.")
    elif type_mode == "syntypes":
        if not treatment.get("syntypes"):
            issues.append("FATAL: syntypes mode selected, but syntype list is missing.")
    else:
```

Taxonomy AI Agent 建设指南 v2.1 - 可实施核实版

```
issues.append("WARN: type-bearing material mode requires human review.")
```

```
# 2. Diagnosis / definition
if not treatment.get("diagnosis") and not treatment.get("definition"):
    issues.append("FATAL: diagnosis or definition is missing.")
if not treatment.get("diagnostic_evidence_ids"):
    issues.append("WARN: diagnosis lacks linked evidence records.")

# 3. Publication metadata
pub = treatment.get("publication", {})
for field in ["date", "archive", "issn_or_isbn"]:
    if not pub.get(field):
        issues.append(f"WARN: publication metadata missing {field}.")
return issues
```

6. 影像与图版：从人工确认元数据开始

显微图、SEM、甲基绿染色图版都可以纳入 Agent，但最稳妥的实现不是先做自动识别，而是先建立影像资产登记。

步骤	可实施做法	不要这样做
命名	IMG_物种或项目_标本 ID_器官_视角_序号.tif	不要只用相机默认 DSC_0001。
比例尺	scale_bar_um 字段由拍摄者或审稿者手动确认。	不要让 OCR 自动读比例尺后直接进入稿件。
景深堆叠	Helicon/Fiji/ImageJ/显微镜软件均可；记录 stack_source 和 final_image。	不要把某个商业软件写成必需依赖。
图版布局	先自动生成候选 plate，人工确认后再写 figure legend。	不要让 Agent 最终决定哪些图能证明诊断性状。
MGS	记录染色范围、强弱和观察条件；作为证据候选。	不要在同属覆盖不足时直接称为 strong diagnostic。

7. 分子证据：证据链，不是自动判种器

COI、16S、18S、28S、线粒体基因组都可以进入证据链。v2.1 建议先实现“序列与标本绑定 + 距离矩阵 + 树文件索引 + accession 校验”，不要一开始做自动物种界定黑箱。

项目	建议
条形码距离	记录 K2P/uncorrected p-distance、最近相似种、矩阵文件路径；不同类群阈值不同，不设 universal cutoff。
系统树	记录模型、软件版本、支持率类型、树文件路径。Agent 可摘要，不可凭摘要改 taxonomy。
隐存种提示	若形态无明显差异但分子分化明显，输出“候选隐存种/需人工审核”，不直接发布新种。
GenBank	accession 应由你上传后确认；Agent 只能检查格式和缺失。

8. 比较引擎与检索表：可运行的逻辑修订

v2.0 的比较引擎思路正确，但需要修正 unknown 处理。所有字符串 unknown、not_examined、?、NA 都应被视为未覆盖，而不是已知状态。

```
# comparator_core.py - safer coverage logic
UNKNOWN_TOKENS = {"", "na", "n/a", "none", "unknown", "not_examined", "?", "missing"}

def is_known(x):
    if x is None:
        return False
```

```
s = str(x).strip().lower()
return s not in UNKNOWN_TOKENS

def compare_character(target_value, congener_values, min_coverage=0.80):
    if not is_known(target_value):
        return {"status": "target_unknown"}
    known = [v for v in congener_values if is_known(v)]
    coverage = len(known) / max(len(congener_values), 1)
    if coverage < min_coverage:
        return {"status": "potential_only", "coverage": coverage}
    if str(target_value) not in [str(v) for v in known]:
        return {"status": "strong_candidate", "coverage": coverage}
    return {"status": "shared_or_not_diagnostic", "coverage": coverage}
```

检索表 validator 的真实边界

树结构 validator 可以检查循环、重复终点、不可达 taxon，但不能证明 couplet 的语义互斥。若要验证“每个物种是否真的能走到唯一终点”，必须把 key 与 character matrix 一起运行。

9. 90 天实施路线：保守、可验收、可扩展

时间	目标	具体产出	验收标准
第 1-2 周	选 pilot 属/类群，统一字段。	建立 project folder、6 个 CSV 模板、术语字典 v0.1。	10-20 个标本记录可导入，无空白关键字段。
第 3-4 周	完成性状比较 baseline。	compare_matrix.py、差异报告模板、unknown 检查。	能正确区分 strong / potential / unknown。
第 5-6 周	完成坐标 QC 和地图脚本包装。	coordinates.csv、map_qc_report.csv、R/Python 制图脚本。	内陆异常、经纬度反转、缺失坐标能被标记。
第 7-8 周	加入影像资产和图注。	images.csv、figure_caption_draft.py。	每个 panel 能回溯到 specimen_id 和原图。
第 9-10 周	加入分子证据表和 ICZN 检查清单。	sequences.csv、molecular_summary.md、iczn_check_minimal.py。	可以输出投稿前缺项清单。
第 11-12 周	Agent 化与回归测试。	10-20 道 benchmark、corrections.jsonl、可选 MCP wrapper。	所有核心错误题不退化；AI 输出均带证据状态。

90 天合理目标

90 天目标不是“全自动分类学工作台”，而是“一个属的可复现 pilot workflow”：能读数据、比性状、查坐标、关联图片、生成分模块草稿，并给出错误/缺项报告。

10. 附录：v2.1 检查清单与参考来源

检查项	通过标准
数据层	所有分类事实必须来自 CSV/SQLite/PDF 原文摘录，不来自 LLM 记忆。
Unknown 铁律	UNKNOWN/NOT_EXAMINED 不参与“缺如”判断。
Gemini/LLM	只负责调度、摘要、写作和审查；工具执行由本地脚本完成。
ICZN	硬性字段自动查，命名学解释人工审。
影像	比例尺、器官、图版 panel 均能回到原始图像和 specimen_id。
分子	距离和树是证据，不是自动判种器。
Benchmark	每次修改 rules/prompts/tools 后都跑回归题库。

参考来源（人工核实用）

Google AI for Developers. Gemini API documentation: multimodal input, structured outputs, function calling, tools, document understanding, agents.

Google AI for Developers. Function calling with the Gemini API: the application executes function code; the model returns function name and arguments.

Model Context Protocol documentation: MCP is an open-source standard for connecting AI applications to external systems.

TDWG Darwin Core Quick Reference Guide: currently recommended terms for biodiversity records.

International Commission on Zoological Nomenclature resources: ICZN Code, electronic publication amendments, ZooBank guidance, and relevant declarations. Use original Code and journal instructions before submission.